

LOG3210 Cours 7

Génération de code intermédiaire (suite)



Types

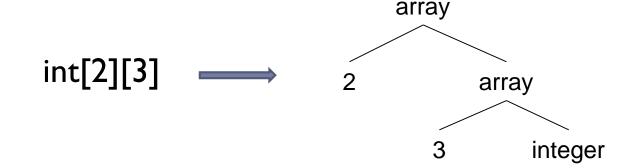
- Les types dans un langage de programmation permettent au compilateur d'effectuer différentes opérations :
 - Vérifications de types (ex. Les opérandes d'un opérateur logique doivent être des valeurs booléennes.)
 - 2. Déterminer l'espace requis. (ex. Un entier requiert 4 octets.)
 - 3. Détecter les conversions de types.
 - Sélectionner les opérateurs appropriés
 (ex. + : addition arithmétique ou concaténation de strings)



Représentation des types

- Les types peuvent être des structures complexes.
- Outre les types de base (int, boolean, float, char, etc.) qui sont facilement représentables par attributs, les types plus complexes peuvent requérir une représentation par structures de données spécialisées.

Exemple:





Déclarations

Nous utiliserons la grammaire suivante pour étudier les déclarations de types:

```
D \rightarrow T id; D | \varepsilon
T \rightarrow B C | record '{' D '}'
B \rightarrow int | float
C \rightarrow \varepsilon | [ num ] C
```



Déclarations

En supposant que les int occupent 4 bytes, les float 8 bytes et en ignorant les record, suggérez une SDT pour déterminer le type et l'espace requis pour T. (Fig. 6.15)

```
T 
ightarrow B \ C { t = B.type; w = B.width; } \ B 
ightarrow int  { B.type = integer; B.width = 4; } \ B 
ightarrow float  { B.type = float; B.width = 8; } \ C 
ightarrow \epsilon { C.type = t; C.width = w; } \ C 
ightarrow [ num ] C_1  { array(num.value, C_1.type); \ C.width = num.value 	imes C_1.width; } \}
```

Figure 6.15: Computing types and their widths



Séquences de déclarations

- Des langages comme le C et le Java permettent de traiter en même temps toutes les déclarations contenues dans une procédure.
- Au moment d'analyser une procédure, on peut donc considérer que les déclarations sont faites de manière séquentielle et allouer des adresses contigües.
- Voir Fig. 6.17



Séquences de déclarations

Au moment d'analyser une procédure, on peut donc considérer que les déclarations sont faites de manière séquentielle et allouer des adresses contigües.

```
P 
ightarrow \{ \textit{offset} = 0; \}
D
D 
ightarrow T \text{ id }; \{ \textit{top.put}(\text{id.lexeme}, T.type, offset); \\ \textit{offset} = \textit{offset} + T.width; \}
D_1
D 
ightarrow \epsilon
```

Figure 6.17: Computing the relative addresses of declared names



Champs d'un enregistrement

Un enregistrement (record) dans notre grammaire définit un nouveau scope où il est possible de définir des champs qui ont le même nom que d'autres variables précédemment déclarées.

Par exemple:

```
float x;
record { float x; float y; } p;
record { int tag; float x; int y; } q;
```

Voir Fig. 6.18



Champs d'un enregistrement

Un enregistrement (record) dans notre grammaire définit un nouveau scope où il est possible de définir des champs qui ont le même nom que d'autres variables précédemment déclarées.

```
T 	o \mathbf{record} '{' { Env.push(top); top = \mathbf{new} Env(); Stack.push(offset); offset = 0; } D '}' { T.type = record(top); T.width = offset; top = Env.pop(); offset = Stack.pop(); }
```

Figure 6.18: Handling of field names in records



Exercice

À quelle offset mémoire se situe la variable q.x?

```
float x;
record { float x; float y; } p;
int[42] a;
record { int tag; float x; int y; } q;
```

Dessinez l'arbre de parsage annoté pour ce programme.



Traduction des expressions

Une partie importante de la génération de code intermédiaire est la traduction d'expressions en code à 3 adresses.

- Une expression à plusieurs opérateurs (a + b * c) sera traduite en plusieurs instructions à 3 adresses d'une opération chacune.
- ▶ Considérons un exemple simple...



Traduction des expressions

Production	SDD
$S \rightarrow id = E;$	S.code = E.code gen(top.get(id.lexeme) '=' E.addr)
$E \rightarrow E_1 + E_2$	E.addr = new Temp() E.code = E_1 .code E_2 .code gen(E.addr '=' E_1 .addr + E_2 .addr)
E → - E ₁	E.addr = new Temp() E.code = E ₁ .code gen(E.addr '=' 'minus' E ₁ .addr)
$E \rightarrow (E_I)$	$E.addr = E_1.addr$ $E.code = E_1.code$
$E \rightarrow id$	E.addr = top.get(id .lexeme) E.code = ' '

Top est une référence à une table de symboles, Temp() crée une nouvelle variable temporaire et gen génère une instruction à 3 adresses.



Traduction des expressions

As-t-on vraiment besoin de concaténer les instructions générées? Peut-on les générer de manière incrémentielle?

Production	SDT
$S \rightarrow id = E;$	{ gen(top.get(id.lexeme) '=' E.addr); }
$E \rightarrow E_1 + E_2$	{ E.addr = new Temp(); gen(E.addr '=' E ₁ .addr + E ₂ .addr); }
E → - E _I	{ E.addr = new Temp(); gen(E.addr '=' 'minus' E ₁ .addr); }
$E \rightarrow (E_I)$	{ E.addr = E _I .addr; }
$E \rightarrow id$	{ E.addr = top.get(id.lexeme); }



Éléments d'un tableau

▶ En supposant que les index (i) d'un tableau commencent à 0, si on connait le type des éléments et donc l'espace requis pour chaque élément (w), il est possible de calculer l'adresse de chacun des éléments à partir de l'adresse de la première case (base):

base
$$+ i \times w$$

En plusieurs dimensions:

base +
$$i_1 \times w_1 + i_2 \times w_2 + ... + i_k \times w_k$$

SDT pour les références aux tableaux



Production	SDT
$S \rightarrow id = E$;	{ gen(top.get(id.lexeme) '=' E.addr); }
$S \rightarrow L = E;$	{ gen(L.array.base '[' L.addr ']' '=' E.addr); }
$E \rightarrow E_1 + E_2$	{ E.addr = new Temp(); gen(E.addr '=' E ₁ .addr + E ₂ .addr); }
$E \rightarrow id$	{ E.addr = top.get(id.lexeme); }
E → L	{ E.addr = new Temp(); gen(E.addr '=' L.array.base '[' L.addr ']'); }
L → id [E]	{ L.array = top.get(id.lexeme); L.type = L.array.type.elem; L.addr = new Temp(); gen(L.addr '=' E.addr '*' L.type.width); }
$L \rightarrow L_1 [E]$	{ L.array = L ₁ .array; L.type = L ₁ .type.elem; t = new Temp(); L.addr = new Temp(); gen(t '=' E.addr '*' L.type.width); gen(L.addr '=' L ₁ .addr '+' t); }



Vérification de types

Nous avons vu comment détecter le type des variables au moment de leur déclaration.

- Au moment de la compilation, le compilateur procède à une vérification des types afin de détecter des erreurs. Par exemple:
 - int[] array = new char[100];
 - Square sq = new Circle();
 - int[] array = new int[100]; array[0] = 234.67;



Typage fort versus faible

- On fera la distinction entre les langages fortement et faiblement typés.
- Un compilateur pour un langage fortement typé garantie l'absence d'erreurs de types à l'exécution. En d'autres mots, il élimine le besoin de vérifier les types à l'exécution. (D'autres définitions existent.)
- Si le langage est faiblement typé, le compilateur peut détecter certaines erreurs de types mais ne garantie pas leur absence.



Synthèse vs. inférence de types

- Lorsqu'il s'agit de vérification de types, le compilateur peut adopter deux stratégies: la synthèse ou l'inférence de types.
- Si les types des variables sont déclarés avant l'utilisation des variables (C, C++, Java, etc.), il est possible de vérifier les types par synthèse.

Exemple:

c = a + b // Cas de base, les types de a, b et c sont connus

 $c = E_1 + E_2$ // On peut synthétiser les types de E_1 et E_2



Inférence de types

- Si le langage permet l'utilisation de variables dont les types ne sont pas déclarés (Python, PHP, Scala, ML, etc.) il est possible de recourir à l'inférence de types.
- Exemple en ML, un langage fortement typé :
 - fun length(x) =
 if null(x) then 0 else length(tl(x)) + 1;
 - Quelle est le type de la valeur de retour de la fonction length?



Conversion de types

- Les compilateurs doivent régulièrement convertir le type des variables.
 - Exemple: f + i où f est de type float et i est de type integer
- Il est possible qu'aucune instruction machine ne supporte l'addition de variables de types différents.
- Dans l'exemple précédent, il faudrait donc convertir i en un float.
- Augmentons la SDT de l'addition...



Conversion de types (suite)

Production	SDT
$E \rightarrow E_1 + E_2$	<pre>{ E.addr = new Temp(); if (E₁.type == integer && E₂.type == integer) E.type = integer; gen(E.addr '=' E₁.addr + E₂.addr); else { E.type = float; tmp = new Temp(); if (E₁.type == integer) { gen(tmp '=' '(float)' E₁.addr) gen(E.addr '=' tmp + E₂.addr) } else if (E₂.type == integer) { gen(tmp '=' '(float)' E₂.addr) gen(E.addr '=' E₁.addr + tmp) } else { gen(E.addr '=' E₁.addr + E₂.addr); } }</pre>



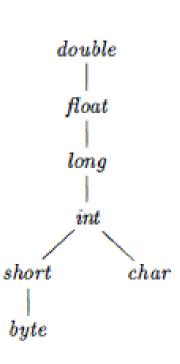
Conversion de type générale

- Évidemment, à partir du moment où on supporte plus que 2 types, augmenter la SDT de cette façon devient ingérable!
- Pour traiter le cas général, nous ferons appel à deux fonctions:
 - \rightarrow max(t₁, t₂) où t₁ et t₂ sont des types.
 - widen(a, t, w) où a est une adresse et où t et w sont des types.



Fonction $max(t_1, t_2)$

- La fonction max(t₁, t₂) prend deux types en paramètre et retourne le premier type en mesure de représenter t₁ et t₂ sans perte d'information.
- Dans l'arbre des conversions à droite, la valeur de max(t₁,t₂) correspond au plus petit ancêtre commun de t₁ et t₂.
- Max retourne une erreur s'il reçoit un paramètre qui n'est pas un type valide.





Fonction widen(a, t, w)

- Cette fonction génère les instructions de code intermédiaire requises pour convertir une variable de type t en un type >= w.
- En d'autres mots, w doit être égal à t ou être un parent de t dans l'arbre des conversions.
- Revisitions la SDT des expressions...

```
Addr widen(Addr a, Type t, Type w)
    if ( t = w ) return a;
    else if ( t = integer and w = float ) {
        temp = new Temp();
        gen(temp '=' '(float)' a);
        return temp;
    }
    else error;
}
```

Figure 6.26: Pseudocode for function widen



Conversion de types générique

Les fonctions max et widen permettent d'isoler la logique de conversion de types de la SDT.

Production	SDT
$E \rightarrow E_1 + E_2$	{ E.addr = new Temp(); E.type = $max(E_1.type, E_2.type)$; a_1 = widen($E_1.addr, E_1.type, E.type$); a_2 = widen($E_2.addr, E_2.type, E.type$); $gen(E.addr '=' a_1 '+' a_2)$; }

Exercice 6.5.1

Surcharge de fonctions et d'opérateurs



- La surcharge de fonctions et d'opérateurs est commune dans les langages de programmation. Les types permettront de déterminer quelle version de la fonction/opérateur doit être appelée.
- Dans les langages comme C, C++ et Java, la surcharge est résolue en fonction des types des arguments de la fonction.
- ▶ En d'autres mots, la surcharge est résolue en faisant correspondre les signatures des fonction appelée et déclarée.



Exemple - Surcharge

```
#include <iostream>
using namespace std;
void print(int i) {
  cout << " Here is int " << i << endl;</pre>
void print(double f) {
  cout << " Here is double " << f << endl;</pre>
void print(string c) {
  cout << " Here is string " << c << endl;</pre>
int main() {
  print(10); //print(10) \Leftrightarrow print(int i)
  print(10.10); //print(10.10) \Leftrightarrow print(double f)
  print("ten"); //print("ten") ⇔ print(string c)
```



Exemple – Surcharge (2)

```
#include <iostream>
using namespace std;
void print(double f) {
  cout << " Here is double " << f << endl;</pre>
void print(string c) {
  cout << " Here is string " << c << endl;</pre>
int main() {
 print(10); //print(10) \( \Delta \) print(double f)
  print(10.10); //print(10.10) \Leftrightarrow print(double f)
 print("ten"); //print("ten") ⇔ print(string c)
```



Exemple – Surcharge (Bonus!)

```
#include <iostream>
using namespace std;
void print(int i, double j) {
  cout << " Here is int " << i << endl;</pre>
  cout << " Here is double " << j << endl;</pre>
void print(double i, int j) {
  cout << " Here is double " << i << endl;</pre>
  cout << " Here is int " << j << endl;</pre>
int main() {
  print(10,10);
```

Retourne quoi...?



Flux de contrôle

- Les structures de contrôle induisent des branchements qui sont résolus à l'exécution.
- Par exemple, les if, while, for, switch, etc. sont toutes des structures de contrôle.
- Traduire des structures de contrôle en code intermédiaire requière évidemment d'être en mesure de traduire des expressions Booléennes.



Expressions Booléennes

- Une expression Booléenne est simplement une expression qui retourne vrai ou faux. La grammaire suivante définit les expressions Booléennes que nous supporterons:
- \rightarrow B || B | B && B | !B | (B) | E rel E | true | false
- où rel est un opérateur relationnel de la forme <, <=, =
 !=, >, ou >=.



Court-circuit

- Étant donné une expression Booléenne, il est parfois possible de connaître le résultat de l'expression après une évaluation partielle.
- ▶ Par exemple: if (x < 100 | | x > 200 && x != y) x = 0;
 - \triangleright Si x < 100, l'expression est vraie
 - Si $x \ge 100$ et que $x \le 200$, l'expression est fausse
 - Si $x \ge 100$ et $x \ge 200$, alors il faut vérifier si $x \ne y$
- À quoi ressemblerait le code intermédiaire?

Traduction des structures de contrôle



Nous construirons tout d'abord une SDT pour les structures de contrôle qui répondent à la grammaire suivante:

$$S \rightarrow if (B) S_1$$

 $S \rightarrow if (B) S_1 else S_2$
 $S \rightarrow while (B) S_1$

 où B est un non terminal qui représente un expression Booléenne.

Traduction des structures de contrôle (suite)



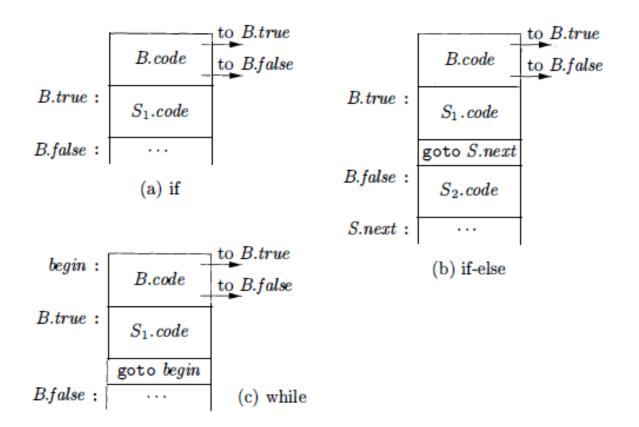


Figure 6.35: Code for if-, if-else-, and while-statements



SDD – Structures de contrôle

PRODUCTION	SEMANTIC RULES
$P \rightarrow S$	S.next = newlabel()
	$P.code = S.code \mid\mid label(S.next)$
$S \rightarrow \mathbf{assign}$	S.code = assign.code
$S \rightarrow \mathbf{if} (B) S_1$	B.true = newlabel()
	$B.false = S_1.next = S.next$
	$S.code = B.code \mid\mid label(B.true) \mid\mid S_1.code$
$S \rightarrow \mathbf{if} (B) S_1 \mathbf{else} S_2$	B.true = newlabel() B.false = newlabel()
	$S_1.next = S_2.next = S.next$
	S.code = B.code $ label(B.true) S_1.code$
	$ label(B.false) S_2.code$
$S \rightarrow \mathbf{while} (B) S_1$	begin = newlabel()
	B.true = newlabel() B.false = S.next
	$S_1.next = begin$
	S.code = label(begin) B.code
	$ label(B.true) S_1.code$
	gen('goto' begin)
$S \rightarrow S_1 S_2$	$S_1.next = newlabel()$
	$S_2.next = S.next$
	$S.code = S_1.code \mid label(S_1.next) \mid S_2.code$



SDD – Expressions Booléennes

PRODUCTION	SEMANTIC RULES
$B \rightarrow B_1 \mid \mid B_2$	$B_1.true = B.true$
	$B_1.false = newlabel()$
	$B_2.true = B.true$
	$B_2.false = B.false$
	$B.code = B_1.code \mid\mid label(B_1.false) \mid\mid B_2.code$
$B \rightarrow B_1 \&\& B_2$	$B_1.true = newlabel()$
	$B_1.false = B.false$
	$B_2.true = B.true$
	$B_2.false = B.false$
	$B.code = B_1.code \mid label(B_1.true) \mid B_2.code$
$B \rightarrow ! B_1$	$B_1.true = B.false$
•	$B_1.false = B.true$
	$B.code = B_1.code$
$B \rightarrow E_1 \operatorname{rel} E_2$	$B.code = E_1.code \mid\mid E_2.code$
$D \rightarrow D_1 \text{ rer} D_2$	gen('if' E ₁ .addr rel.op E ₂ .addr 'goto' B.true)
	$\parallel gen('goto' B.false)$
$B \rightarrow \mathbf{true}$	B.code = gen('goto' B.true)
	- 12
$B \rightarrow \mathbf{false}$	B.code = gen('goto' B.false)



Exemple de traduction

Traduisons le segment de code suivant avec les SDD précédentes:

if
$$(x < 100 || x > 200 && x != y) x = 0;$$

Le résultat est-il optimal?

Élimination des GOTO redondants



Dans l'exemple précédent, nous générions le code intermédiaire suivant:

if
$$x > 200$$
 goto L_4 goto L_1
 \dots

Il est simple de constater que l'instruction suivante accompli la même tâche:

ifFalse
$$x > 200$$
 goto L_1 : ...

Élimination des GOTO redondants (suite)



- L'idée est de profiter de la séquence naturelle des instructions et d'éviter des GOTO inutiles.
- L'instruction fall servira à signaler qu'il ne faut pas générer de GOTO.
- Les instructions de type if-else et while fixent aussi B.true à fall.

	WONTREA
PRODUCTION	SEMANTIC RULES
$P \rightarrow S$	S.next = newlabel()
	$P.code = S.code \mid\mid label(S.next)$
$S \rightarrow \mathbf{assign}$	S.code = assign.code
$S \rightarrow \mathbf{if} (B) S_1$	B.true = fall $B.false = S_1.next = S.next$
	$S.code = B.code \mid\mid S_1.code$
$S \rightarrow \mathbf{if} (B) S_1 \mathbf{else} S_2$	B.true = newlabel() B.false = newlabel() $S_1.next = S_2.next = S.next$ S.code = B.code $ label(B.true) S_1.code$ gen('goto' S.next) $ label(B.false) S_2.code$
$S \rightarrow $ while $(B) S_1$	$begin = newlabel()$ $B.true = newlabel()$ $B.false = S.next$ $S_1.next = begin$ $S.code = label(begin) B.code$ $ label(B.true) S_1.code$ $ gen('goto' begin)$
$S \rightarrow S_1 S_2$	$S_1.next = newlabel()$ $S_2.next = S.next$ $S.code = S_1.code \mid\mid label(S_1.next) \mid\mid S_2.code$

Traduction des opérateurs relationnels



```
test = E_1.addr \, \mathbf{rel.}op \, E_2.addr
s = \mathbf{if} \, B.true \neq fall \, \mathbf{and} \, B.false \neq fall \, \mathbf{then}
gen('if' \, test'goto' \, B.true) \mid\mid gen('goto' \, B.false)
else \, \mathbf{if} \, B.true \neq fall \, \mathbf{then} \, gen('if' \, test'goto' \, B.true)
else \, \mathbf{if} \, B.false \neq fall \, \mathbf{then} \, gen('ifFalse' \, test'goto' \, B.false)
else''
B.code = E_1.code \mid\mid E_2.code \mid\mid s

Figure 6.39: Semantic rules for B \rightarrow E_1 \, \mathbf{rel} \, E_2
```

Traduction des opérateurs logiques



▶ Dans ce cas-ci, si B.true == fall, il faut tout de même s'assurer de ne pas calculer B_2 inutilement. Si B.true == fall, B_1 va générer un GOTO pour passer par-dessus les instructions de B_2 .

```
B_1.true = \mathbf{if} \ B.true \neq fall \ \mathbf{then} \ B.true \ \mathbf{else} \ newlabel()
B_1.false = fall
B_2.true = B.true
B_2.false = B.false
B.code = \mathbf{if} \ B.true \neq fall \ \mathbf{then} \ B_1.code \ || \ B_2.code
\mathbf{else} \ B_1.code \ || \ B_2.code \ || \ label(B_1.true)
```

Figure 6.40: Semantic rules for $B \to B_1 \mid \mid B_2$

Expressions Booléennes hors des structures de contrôle



- Les expressions Booléennes peuvent être utilisées en dehors des structures de contrôle.
- Exemple: x = a < b && c < d</p>
- Il faudra alors générer le même code avec les GOTO, mais s'assurer que le résultat est bien stocké dans une variable temporaire!
- Une stratégie consiste à faire 2 traversements de l'arbre de parsage. Une fois pour les expressions dans les structures de contrôles et une fois pour les autres expressions en variant la SDT.



Traduction des switch

Normalement, la manière la plus efficace d'implanter un switch est d'utiliser un tableau (< 10 éléments) ou une table de hachage (>= 10 éléments).

```
switch (age) {
          case 1: S_1
          case 2: S<sub>2</sub>
          case 99: S_{n-1}
          default: S<sub>n</sub>
L_1: S_1
L_2: S_2
L_{n-1}: S_{n-1}
L_n: S_n
```

Valeur	Étiquette
I	L _I
2	L_2
•••	•••
99	L_{n-1}
default	L _n



Traduction des switch par SDT

```
\begin{array}{c} \mathbf{switch} \; (\; E \;) \; \{ \\ \mathbf{case} \; V_1 \colon S_1 \\ \mathbf{case} \; V_2 \colon S_2 \\ & \cdots \\ \mathbf{case} \; V_{n-1} \colon S_{n-1} \\ \mathbf{default} \colon S_n \\ \} \end{array}
```

Figure 6.48: Switch-statement syntax

```
code to evaluate E into t
         goto test
         code for S_1
L_1:
         goto next
L_2:
        code for S_2
         goto next
        code for S_{n-1}
L_{n-1}:
         goto next
        code for S_n
L<sub>n</sub>:
         goto next
test: if t = V_1 goto L_1
         if t = V_2 goto L_2
         if t = V_{n-1} goto L_{n-1}
         goto L_n
next:
```

Figure 6.49: Translation of a switch-statement

Traduction des switch par SDT (suite)



- Quand le mot clé switch est rencontré, générer deux étiquettes: test et next et un temporaire t.
- 2. Générer le code pour évaluer E et stocker le résultat dans t.
- 3. Générer un goto vers test
- Pour chaque mot clé case, créer une étiquette L_i et l'insérer dans la table de symboles.
- 5. Insérer une paire (V_i, L_i) représentant la constante du **case** et son étiquette dans une file.
- Émettre l'étiquette L_i accompagnée du code S_i suivi d'un goto next.
- 7. Quand il n'y a plus de **case**, lire la file et émettre une instruction « **case** t V_i L_i »

Traduction des switch par SDT (suite)



```
code to evaluate E into t
        goto test
        code for S_1
L_1:
                                                  Cette forme est plus
        goto next
L_2:
        code for S_2
                                                  facile à convertir en
        goto next
                                                  table de hachage par le
        code for S_{n-1}
L_{n-1}:
                                                  générateur de code.
        goto next
        code for S_n
L<sub>n</sub>:
        goto next
test: if t = V_1 goto L_1
        if t = V_2 goto L_2
        if t = V_{n-1} goto L_{n-1}
        goto L<sub>n</sub>
next:
                                                    next:
```

Figure 6.49: Translation of a switch-statement

test: case t V_1 L₁ case t V_2 L₂ case t V_{n-1} L_{n-1}

case t t L.