















LOG3210 Éléments de langage et compilateurs

Analyse syntaxique

- Parseurs descendants

PLAN

- 1. Chapitre 2 (Suite et Fin)
 - Grammaires ambiguës
 - Associativité et précédence des opérateurs
- 2. Chapitre 4 Parseurs descendants récursifs

PAGE 3			
DEPARTMENT	COURSE	DESCRIPTION	PREREQS
COMPUTER SCIENCE	CPSC 432	INTERMEDIATE COMPILER DESIGN, WITH A FOCUS ON DEPENDENCY RESOLUTION.	CPSC 432
00	0000 1100	March Columba Droich	O. 177



https://xkcd.com/754/ : Dependencies

```
class Etudiant {
    string nom;
    int note;
}// ; // point-virgule manquant
int main(void) {
    return 0;
```



Visual Studio 2013

```
5 □class Etudiant {
6    string nom;
7    int note;
8    }//; // point-virgule manquant
9
10
11 □ int main(void) {
12    return 0;
13    }
14
```

- (11) error C2628: 'Etudiant' suivi de 'int' n'est pas conforme (n'auriez-vous pas oublié un ';' ?)
- (11) error C3874: le type de retour de 'main' doit être 'int' au lieu de 'Etudiant'

```
1>----- Début de la génération : Projet : sandbox, Configuration : Debug Win32 -----
1> main.cpp
1>z:\poly\log3210\h16\sandbox\sandbox\main.cpp(11): error C2628: 'Etudiant' suivi de 'int' n'est pas conforme (n'auriez-vous pas oublié un ';' ?)
1>z:\poly\log3210\h16\sandbox\sandbox\sandbox\main.cpp(11): error C3874: le type de retour de 'main' doit être 'int' au lieu de 'Etudiant'|
```

Apple LLVM version 7.0.2 (clang-700.1.81)

1 error generated.

```
main.cpp:8:2: error: expected ';' after class
}// ; // point-virgule manquant
^
```



```
gcc version 5.1.1 20150618
(Red Hat 5.1.1-4) (GCC)
```

```
main.cpp:8:1: erreur: expected ';' after
  class definition
}//; // point-virgule manquant
```





LOG3210 Cours 2

Analyse syntaxique - Parseurs descendants



Analyse syntaxique



Dérivations

- Il s'agit d'une séquence de remplacements produits via les règles de production
 - $\vdash E \rightarrow -E \rightarrow -(E) \rightarrow -(id)$
- Leftmost derivation (dérivation à gauche)
 - On choisit toujours le non terminal le plus à gauche pour le remplacer
 - ▶ $E \Rightarrow_{lm} E + E \Rightarrow id + E \Rightarrow id + id$
 - $\vdash \mathsf{E} \Rightarrow_{lm}^* \mathsf{id} + \mathsf{id}$
- ▶ Rightmost derivation (dérivation à droite)
 - On choisit toujours le non terminal le plus à droite pour le remplacer
 - ▶ $E \Rightarrow_{rm} E + E \Rightarrow E + id \Rightarrow id + id$



Exercice 1

Donnez une dérivation à gauche et une dérivation à droite pour les grammaires et les chaînes spécifiées:

1.
$$S \rightarrow SS + |SS*|a$$

Chaîne $aa+a*$

Dérivation à gauche :

$$S \Rightarrow_{lm} S S * \Rightarrow S S + S * \Rightarrow a S + S * \Rightarrow aa + S * \Rightarrow aa + a *$$

Dérivation à droite :

$$S \Rightarrow_{rm} S S * \Rightarrow S a^* \Rightarrow S S + a^* \Rightarrow a S + a^* \Rightarrow aa + a^*$$

Exercice supplémentaire

- Donnez une dérivation à gauche et une dérivation à droite pour les grammaires et les chaînes spécifiées:
 - 1. $S \rightarrow S(S)S \mid \varepsilon$ Chaîne (()())
- Donnez l'arbre de parsage.
- Décrivez le langage généré par cette grammaire.
- Exercices supplémentaires à la Section 4.2.8 du Dragon

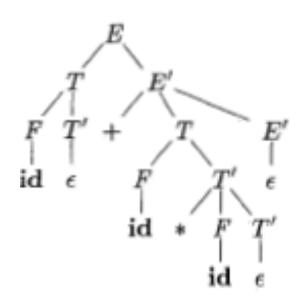
Analyse syntaxique

- CFG générales (applications en IA), peuvent traiter l'ambigüité
 - Earley, Cocke-Younger-Kasami
 - ightharpoonup Espace = $O(n^2)$
 - ightharpoonup Temps = $O(n^3)$
- \rightarrow LL(k) \rightarrow O(n)
 - Contexte gauche (Lecture des jetons de gauche à droite)
 - Dérivation gauche
- \rightarrow LR(k) \rightarrow O(n)
 - Contexte gauche (Lecture des jetons de gauche à droite)
 - Dérivation droite

Analyse syntaxique

On a une chaîne en entrée et une grammaire libre de contexte.

- Comment générer l'arbre de parsage?
- Exemple:





Parseur descendant (top-down)

- Construisent un arbre de parsage à partir de la chaîne en entrée, en partant de la racine de l'arbre.
- Les nœuds sont créés en **préordre** (aka préfixe).
- Le symbole actuellement analysé est référé en tant que lookahead.



Parseur descendant (top-down)

```
stmt \rightarrow expr;
| if (expr) stmt
| for (optexpr; optexpr; optexpr) stmt
| other

optexpr \rightarrow \epsilon
| expr
```

Donnez l'arbre de parsage pour l'expression suivante:

```
for (; expr; expr) other
```



Parseur descendant (top-down)

```
| stmt → expr; | if (expr) stmt | for (optexpr; optexpr; optexpr) stmt | other | other | expr
```

Figure 2.16: A grammar for some statements in C and Java

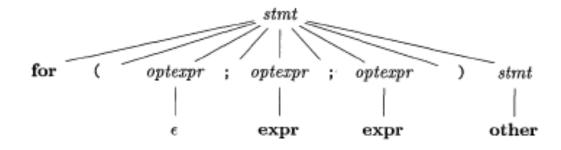


Figure 2.17: A parse tree according to the grammar in Fig. 2.16 for (; expr; expr) other

Parseur descendant (top-down)

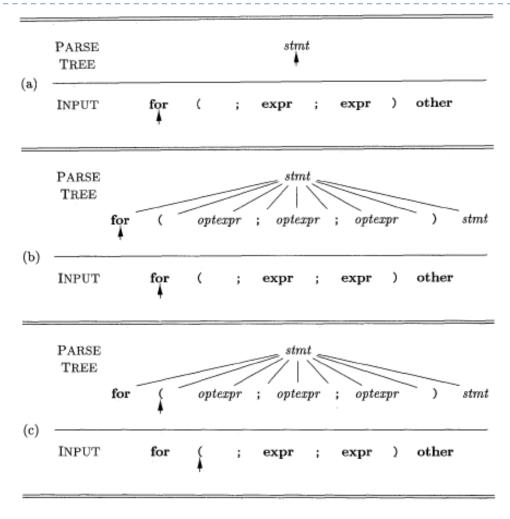


Figure 2.18: Top-down parsing while scanning the input from left to right

Parseur descendant (top-down) Retour en arrière



 Un parseur descendant typique peut nécessiter des retours en arrière (backtracking) si la grammaire n'est pas factorisée.

- **Exemple:**
 - \triangleright S \rightarrow cAd A \rightarrow ab | a

Si on veut reconnaître la chaîne c a d :

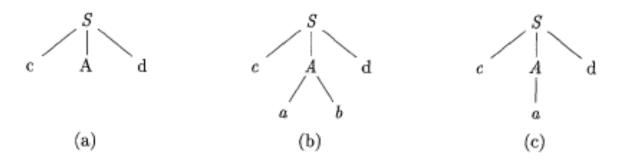


Figure 4.14: Steps in a top-down parse LOG3210 - Cours 2 2016-01-18



Factorisation à gauche

Pour les parseurs top-down, la production à utiliser n'est pas toujours évidente.

- Exemple
 - stmt → if expr then stmt else stmtif expr then stmt
- La factorisation à gauche permet d'éliminer plusieurs cas où du backtracking pourrait être nécessaire.

Factorisation à gauche

- Solution: trouver le préfixe commun aux deux règles et créer un nouveau non terminal pour les parties non communes.
 - > stmt \rightarrow if expr then stmt elsestmt elsestmt | ε
- Globalement:
 - ▶ A → $\alpha\beta_1$ | $\alpha\beta_2$ | ... | $\alpha\beta_n$ | γ | α est le préfixe commun γ représente toutes les règles qui ne commencent pas par α
- Devient:
 - $\rightarrow \alpha A' \mid \gamma$
 - $A' \rightarrow \beta_1 | \beta_2 | \dots | \beta_n$



Récursivité à gauche

- Une grammaire est récursive à gauche si elle contient un non terminal A tel qu'il existe une règle de production A → Aα pour une chaîne α quelconque.
- La récursivité à gauche mène à une boucle infinie pour les analyseurs syntaxiques récursifs en profondeur (recursive-descent parsers).

Élimination de la récursivité directe



- ▶ Soit les productions du type $A \rightarrow A\alpha \mid \beta$.
- Une telle récursivité à gauche peut toujours être éliminée en la remplaçant par les productions suivantes:
 - $A \rightarrow \beta A'$ $A' \rightarrow \alpha A' \mid \varepsilon$
- Cette règle suffit pour la plupart des grammaires.
- Exemple:

►
$$E \rightarrow E + T \mid T$$

 $T \rightarrow T * F \mid F$
 $F \rightarrow (E) \mid id$



Grammaire des expressions

Exemple:

- $\rightarrow E \rightarrow E + T | T$
- $T \rightarrow T * F | F$
- $F \rightarrow (E) \mid id$

▶ En éliminant la récursivité à gauche:

Élimination de la récursivité directe (suite)



- ▶ Dans le cas général, étant donné une règle de production du type : $A \rightarrow A\alpha_1 \mid A\alpha_2 \mid A\alpha_3 \mid \beta_1 \mid \beta_2 \mid \beta_3$
- Il suffit de remplacer la règle par :
 - $A \rightarrow \beta_1 A' \mid \beta_2 A' \mid \beta_3 A'$
 - A' $\rightarrow \alpha_1 A' | \alpha_2 A' | \alpha_3 A' | \epsilon$

Élimination de la récursivité indirecte



La récursivité à gauche peut impliquer plus d'une étape.

$$S \rightarrow Aa \mid b$$

 $A \rightarrow Ac \mid Sd \mid \varepsilon$

Le non terminal S est récursif à gauche, car $S \rightarrow Aa \rightarrow Sda$

L'algorithme 4.19 du livre permet d'éliminer ces récursivités.

Élimination de la récursivité Algorithme



Algorithm 4.19: Eliminating left recursion.

INPUT: Grammar G with no cycles or ϵ -productions.

OUTPUT: An equivalent grammar with no left recursion.

METHOD: Apply the algorithm in Fig. 4.11 to G. Note that the resulting non-left-recursive grammar may have ϵ -productions. \square

```
arrange the nonterminals in some order A<sub>1</sub>, A<sub>2</sub>,..., A<sub>n</sub>.
for ( each i from 1 to n ) {
for ( each j from 1 to i − 1 ) {
replace each production of the form A<sub>i</sub> → A<sub>j</sub>γ by the productions A<sub>i</sub> → δ<sub>1</sub>γ | δ<sub>2</sub>γ | ··· | δ<sub>k</sub>γ, where A<sub>j</sub> → δ<sub>1</sub> | δ<sub>2</sub> | ··· | δ<sub>k</sub> are all current A<sub>j</sub>-productions }
}
eliminate the immediate left recursion among the A<sub>i</sub>-productions }
```

Exercice 2

Eliminez la récursion à gauche des grammaires suivantes

- S → AB
 A → AA | Aa | aa
 B → BB | Bb | bb
- 2. $D \rightarrow EF$ $E \rightarrow Eg \mid Fe$ $F \rightarrow DF \mid f$

Parseur descendant (top-down) Boucle infinie



- Expliquez pourquoi une grammaire récursive à gauche peut causer un analyseur syntaxique descendant (LL) à entrer dans une boucle infinie.
 - \rightarrow Ex.: E \rightarrow E+T|T
- Le parseur peut dériver toujours le même non-terminal, sans consommer aucun jeton en entrée, et tomber ainsi dans une boucle infinie. (Section 4.4.1 du Dragon)



FIRST (Livre du Dragon 4.2.2)

FIRST(α): l'ensemble des terminaux qui peuvent être les premiers symboles de α .

Déterminer FIRST pour tous les symboles

- I. Si X est un terminal, alors $FIRST(X) = \{X\}$
- Si X est un non terminal et que $X \rightarrow Y_1Y_2...Y_k...$ est une production, ajouter a dans FIRST(X) si pour un i quelconque, a est dans FIRST(Y_i) et ϵ est dans FIRST(Y_i), ..., FIRST(Y_{i-1}). Si ϵ est dans FIRST(Y_i) pour j = 1, 2, ..., k, alors ajouter ϵ à FIRST(X). **Règle générale**: FIRST(Y_i) est sûrement dans FIRST(X). Si Y_i ne dérive pas ϵ , rien d'autre n'est ajouté dans FIRST(X) Si Y_i dérive ϵ , on ajoute FIRST(Y_i). Continuer la même règle avec Y_i , etc.
- Si X $\rightarrow \epsilon$ est une production, ajouter ϵ à FIRST(X)



FIRST (Livre du Dragon 4.2.2)

FIRST(α): l'ensemble des terminaux qui peuvent être les premiers symboles de α .

Déterminer FIRST pour tous les symboles

- I. Si X est un terminal, alors $FIRST(X) = \{X\}$
- Si X est un non terminal et que $X \rightarrow Y_1 Y_2 ... Y_k ...$ est une production, ajouter a dans FIRST(X) si pour un i quelconque, a est dans FIRST(Y_i) et ϵ est dans FIRST(Y_1), ..., FIRST(Y_{i-1}). Si ϵ est dans FIRST(Y_j) pour j = 1, 2, ..., k, alors ajouter ϵ à FIRST(X).
- 3. Si $X \rightarrow \varepsilon$ est une production, ajouter ε à FIRST(X)
- ▶ **FIRST**($X_1, X_2, ..., X_n$) : Ajouter FIRST(X_1) sauf ε. Si ε ∈ FIRST(X_1), ajouter FIRST(X_2) sauf ε, etc.



FOLLOW (Livre du Dragon 4.2.2)

FOLLOW(A): l'ensemble des terminaux a pouvant apparaître immédiatement à la droite de A. Si A peut être le symbole le plus à droite, on ajoute alors \$ à l'ensemble FOLLOW.

Déterminer FOLLOW pour tous les non terminuax

- Placer \$ dans FOLLOW(S), où S est le symbole de départ et \$ est le marqueur de fin.
- 2. S'il existe une production $A \rightarrow \alpha B\beta$, tout ce qui est dans FIRST(β), à l'exception de ϵ , est dans FOLLOW(B).
- S'il existe une production $A \rightarrow \alpha B$, ou encore une production $A \rightarrow \alpha B\beta$ où FIRST(β) contient ϵ , ajouter tout ce qui est dans FOLLOW(A) dans FOLLOW(B)



Exercice 3

▶ Calculer les FIRST et FOLLOW de la grammaire suivante:

- \rightarrow E \rightarrow T G
- ightharpoonup G → +TG | ε
- \rightarrow T \rightarrow F H
- H → *FH | ε
- $F \rightarrow (E) \mid id$



Exercice 3 (solution)

- FIRST(F) = FIRST(T) = FIRST(E) = { (, id }
- $\blacktriangleright \mathsf{FIRST}(G) = \{ +, \varepsilon \}$
- $\blacktriangleright \mathsf{FIRST}(H) = \{ *, \varepsilon \}$
- FOLLOW(E) = FOLLOW(G) = {), \$ }
- FOLLOW(T) = FOLLOW(H) = { +,), \$ }
- FOLLOW(F) = { +, *,), \$ }



Grammaires LL(1)

Les grammaires LL(I) sont un sous-ensemble des CFG.

- Premier L: lecture de gauche à droite (Left to right)
- ▶ Deuxième L: dérivation à gauche (Lefmost derivation)
- ▶ Chiffre I: un seul symbole de *lookahead* est utilisé pour sélectionner la prochaine production.
- La plupart des constructions que l'on retrouve en programmation peuvent être représentées par une grammaire LL(I).
 - Attention, les grammaires LL(I) ne doivent être ni récursives à gauche, ni ambiguës. Elles ont aussi été factorisées à gauche.



Grammaires LL(1)

Conditions pour qu'une grammaire soit LL(I)

- ▶ Pour deux productions $A \rightarrow \alpha \mid \beta$ distinctes:
 - 1. FIRST(α) et FIRST(β) sont deux ensembles disjoints.
 - Factorisée à gauche.
 - 2. Au plus un de α et β peut dériver la chaîne vide ϵ (déjà spécifié en I).
 - 3. Si β peut éventuellement dériver ϵ (ϵ est dans FIRST(β)), alors FIRST(α) et FOLLOW(A) sont disjoints. De même, si α peut éventuellement dériver ϵ (ϵ est dans FIRST(α)), alors FIRST(β) et FOLLOW(A) sont disjoints.

Analyseur syntaxique descendant Implémentation



Un ensemble de procédures récursives est utilisé pour reconnaître l'entrée.

- Une procédure est associée à chaque non terminal de la grammaire.
- Description match(jeton) : vérifie que jeton est égal au symbole lookahead courant, puis incrémente le lookahead.

Analyseur syntaxique prédictif (descendant)



- Un analyseur syntaxique prédictif peut être construit pour une grammaire LL(I).
- Un analyseur syntaxique prédicitf est un analyseur descendant récursif qui ne requiert pas de retour en arrière.

Seul le symbole courant doit être pris en compte pour choisir la règle à sélectionner.

Construction d'un analyseur syntaxique prédictif (descendant)



- Produire une méthode pour chaque non terminal A.
- ▶ Pour chaque production $A \rightarrow \alpha$ de la grammaire:
 - 1. Si lookahead \in FIRST(α), appeler les méthodes de α .
 - 2. Si $\varepsilon \in \mathsf{FIRST}(\alpha)$ et que *lookahead* $\in \mathsf{FOLLOW}(A)$, appeler les méthodes de α .
 - Si $\alpha = \varepsilon$, alors ne rien faire.
- Etant donné la méthode correspondant au non terminal A, tous les jetons qui n'ont pas été traités au point précédent génèrent une erreur.

Analyseur syntaxique prédictif (descendant)



```
stmt \rightarrow expr;
| if (expr) stmt
| for (optexpr; optexpr; optexpr) stmt
| other

optexpr \rightarrow \epsilon
| expr
```

• Écrivons un analyseur syntaxique descendant pour cette grammaire.

Analyseur syntaxique prédictif (Solution naïve)



```
void stmt() \{
      switch ( lookahead ) {
      case expr:
             match(expr); match(';'); break;
      case if:
             match(\mathbf{if}); match('('); match(\mathbf{expr}); match(')'); stmt();
             break:
      case for:
             match(for); match('(');
             optexpr(); match(';'); optexpr(); match(';'); optexpr();
             match(')'); stmt(); break;
      case other:
             match(other); break;
      default:
             report("syntax error");
void optexpr() {
      if ( lookahead == expr ) match(expr); Support pour le \epsilon
void match(terminal\ t) {
      if (lookahead == t) lookahead = nextTerminal;
      else report("syntax error");
```

Analyseur syntaxique prédictif (Solution avec détection d'erreurs poly)

```
void stmt() \{
     switch ( lookahead ) {
     case expr:
           match(expr); match(';'); break;
      case if:
           match(\mathbf{if}); match('('); match(\mathbf{expr}); match(')'); stmt();
            break:
      case for:
            match(\mathbf{for}); match('('));
            optexpr(); match(';'); optexpr(); match(';'); optexpr();
            match(')'); stmt(); break;
      case other:
            match(other); break;
      default:
                                                    if ( lookahead == expr)
            report("syntax error");
                                                                match (expr);
                                                    else if ( lookahed == ';' )
                                                                ; // do nothing
void optexpr() {
                                                    else if ( lookahed == ')' )
      if ( lookahead == expr ) match(expr);
                                                                ; // do nothing
                                                    else
void match(terminal\ t) {
      if ( lookahead == t ) lookahead = nextTerminal;
                                                                report("syntax error");
      else report("syntax error");
```

∍ ÉCOLF



Exercice 4

- En considérant que:
 - La fonction "boolean match(int jeton)" est déjà définie.
 - Les jetons de type int : <id>, <true>, <false>, <parenthese gauche>, <parenthese droite>, <or> et <and> sont déjà définis.
 - La variable globale *lookahead* contient le jeton courant.
- Écrivez le code de l'analyseur syntaxique descendant récursif correspondant à la grammaire suivante:

```
► E \rightarrow MF

F \rightarrow V E \mid \varepsilon

M \rightarrow W N

N \rightarrow \bigwedge M \mid \varepsilon

W \rightarrow id \mid true \mid false \mid (E)
```



Exercice supplémentaire

- Considérez la chaîne:(id ∧ true) ∨ (id ∨ false)
- Donnez une dérivation à gauche (leftmost derivation) pour la chaîne considérée.
- Donnez une dérivation à droite (rightmost derivation) pour la chaîne considérée.
- Donnez un arbre d'analyse syntaxique (parse tree) pour la chaîne considérée

PARSEURS DESCENDANTS DANS LE MONDE OPEN SOURCE



GCC 3.4.0 (Avril 2004)

- « A <u>hand-written recursive-descent C++ parser</u> has replaced the YACC*-derived C++ parser from previous GCC releases. The new parser contains much improved infrastructure needed for better parsing of C++ source codes, handling of extensions, and clean separation (where possible) between proper semantics analysis and parsing. The new parser fixes many bugs that were found in the old parser. »
- * Yacc est un générateur de parseurs LR (ascendant)

PARSEURS DESCENDANTS DANS LE MONDE OPEN SOURCE



« A single unified parser for C, Objective C, C++, and **Objective C++**

Clang is the "C Language Family Front-end", which means we intend to support the most popular members of the C family. We are convinced that the right parsing technology for this class of languages is a hand-built recursive-descent parser. Because it is plain C++ code, recursive descent makes it very easy for new developers to understand the code, it easily supports ad-hoc rules and other strange hacks required by C/C++, and makes it straight-forward to implement excellent diagnostics and error recovery. »

PARSEURS DESCENDANTS DANS LE MONDE OPEN SOURCE



« Expressive Diagnostics

In addition to being fast and functional, we aim to make Clang extremely user friendly. As far as a command-line compiler goes, this basically boils down to making the diagnostics (error and warning messages) generated by the compiler be as useful as possible. There are several ways that we do this, but the most important are pinpointing exactly what is wrong in the program, highlighting related information so that it is easy to understand at a glance, and making the wording as clear as possible. »

PARSEURS DESCENDANTS RÉCURSIFS

Lectures supplémentaires

```
Eli Bendersky,

« Recursive descent, LL and predictive parsers »,

<a href="http://eli.thegreenplace.net/2008/09/26/recursive-">http://eli.thegreenplace.net/2008/09/26/recursive-</a>
```

descent-II-and-predictive-parsers

```
Josh Haberman, « LL and LR in Context: Why 
Parsing Tools Are Hard », 
http://blog.reverberate.org/2013/09/II-and-Ir-in-
context-why-parsing-tools.html
```