







### LOG3210 Éléments de langage et compilateurs

Analyse syntaxique

- Parseurs ascendants

#### **PLAN**

- 1. Chapitre 4 Parseurs descendants (Suite et Fin)
  - Implémentation d'un parseur LL
  - Génération d'un parseur par JavaCC
- 2. Chapitre 4 Parseurs ascendants (Début)



#### **CHAPITRE 4 – JAVACC**

JavaCC est un générateur de parseur Java Compiler Compiler

JJTree ajoute des méthodes utilitaires à la grammaire .jjt et produit un fichier .jj

JavaCC génère un parseur à partir de ce fichier .jj (voir LEParser.java)



#### **CHAPITRE 4 – JAVACC**

```
Règle de production: Program → Block <EOF>
final public ASTProgram Program() throws
                                  ParseException {
 ASTProgram jjtn000 =
            new ASTProgram(this, JJTPROGRAM);
  boolean jjtc000 = true;
  jjtree.openNodeScope(jjtn000);
  try {
              Program → Block <EOF>
      Block();
      jj_consume_token(0);
      jjtree.closeNodeScope(jjtn000, true);
```

#### **CHAPITRE 4 – JAVACC**

```
Règle de production:
  E \rightarrow T (<+>T)*
final public void AddExpr() {
  try {
      MultExpr();
  label 2:
      while (true) {
        switch (jj_ntk) {
        case PLUS:
        case MINUS:
           break:
        default:
           break label_2;
```

```
}
switch (jj_ntk) {
case PLUS:
  jj_consume_token(PLUS);
  break:
case MINUS:
  jj consume token(MINUS);
  break:
default:
  jj_consume_token(-1);
  throw new
        ParseException();
MultExpr();
```



LOG3210 Cours 3

Analyse syntaxique – Parseurs ascendants

### Table de parsage Parseurs descendants



- Les parseurs top-down construisent une table de parsage, plus rapide à l'exécution que les méthodes récursives.
- ▶ Cette table est un tableau à deux dimensions M[A, a] où
  - A est un non terminal
  - a est un terminal ou le symbole \$ (fin de l'entrée)
- Exemple:

$$\begin{array}{ccccc} E & \rightarrow & T \ E' \\ E' & \rightarrow & + T \ E' \mid \epsilon \\ T & \rightarrow & F \ T' \\ T' & \rightarrow & * F \ T' \mid \epsilon \\ F & \rightarrow & (E) \mid \mathbf{id} \end{array}$$

### Table de parsage Parseurs descendants



Example 4.32: For the expression grammar (4.28), Algorithm 4.31 produces the parsing table in Fig. 4.17. Blanks are error entries; nonblanks indicate a production with which to expand a nonterminal.

Non -	INPUT SYMBOL					
TERMINAL	id	+	*	(	)	- \$
E	$E \to TE'$			$E \to TE'$		
E'		$E' \rightarrow +TE'$			$E' \to \epsilon$	$E' \to \epsilon$
T	$T \to FT'$			$T \rightarrow FT'$		
T'		$T' \rightarrow \epsilon$	$T' \to *FT'$	}	$T' \rightarrow \epsilon$	$T' \rightarrow \epsilon$
F	$F  o \mathbf{id}$			$F \rightarrow (E)$		

Figure 4.17: Parsing table M for Example 4.32

## Construction de la table Parseurs descendants



- On construit la table de parsage en suivant les étapes suivantes (algorithme 4.31 du livre):
- ▶ Pour chaque production  $A \rightarrow \alpha$  de la grammaire:
  - Pour chaque terminal a dans FIRST( $\alpha$ ), ajouter  $A \rightarrow \alpha$  dans M[A,a]
  - 2. Si  $\varepsilon$  est dans FIRST( $\alpha$ ), alors pour chaque terminal b dans FOLLOW(A), ajouter  $A \rightarrow \alpha$  dans M[A,b]. Si  $\varepsilon$  est dans FIRST( $\alpha$ ) et \$ est dans FOLLOW(A), ajouter également  $A \rightarrow \alpha$  à M[A,\$]
- Si, à la fin, il n'y a aucune production dans M[A,a], insérer
   error dans M[A,a]

# ÉCOLE POLYTECHNIQUE M O N T R É A L

#### Exercice 1

Bâtir la table de parsage de l'analyseur descendant pour la grammaire suivante:

- $\rightarrow A \rightarrow BC$
- $\rightarrow B \rightarrow bB \mid \varepsilon$
- $\rightarrow C \rightarrow cC \mid \varepsilon$

Pour chaque case où il y a **error**, donnez un message d'erreur pertinent pour l'utilisateur



## Exercice 1 (solution)

▶ FIRST(A) = 
$$\{b, c, \epsilon\}$$
 FOLLOW(A) =  $\{\$\}$ 

▶ FIRST(B) = 
$$\{b, \epsilon\}$$
 FOLLOW(B) =  $\{c, \$\}$ 

▶ FIRST(
$$C$$
) = {  $c$ ,  $\varepsilon$  } FOLLOW( $C$ ) = { \$ }

Non	Symboles d'entrée			
terminaux	b	C	\$	
Α	$A \rightarrow BC$	$A \rightarrow BC$	A→BC	
В	B → bB	<b>B</b> → ε	<b>B</b> → ε	
С	ENCOUNTERED b, EXPECTING c or \$	C→cC	C → ε	

### Table de parsage Parseurs descendants



- L'ambiguïté se manifeste dans la table de parsage.
  - Certains langages n'ont pas de grammaire LL(I)

Non -		INPUT SYMBOL				
TERMINAL	a	b	e	i	t	- \$
S	$S \rightarrow a$			$S \rightarrow iEtSS'$		
S'			$S' \to \epsilon$			$S' \rightarrow \epsilon$
			$S' \to \epsilon$ $S' \to eS$			
E		$E \rightarrow b$				

Figure 4.18: Parsing table M for Example 4.33

## Analyse syntaxique ascendante (bottom-up parsing)



- Aussi appelé parsage décalage / réduction (shift/reduce parsing)
- Forme générale: LR parsing
- Idée:
  - Construire un arbre de parsage à partir des feuilles vers la racine





Figure 4.25: A bottom-up parse for id \* id



## Analyse syntaxique ascendante

Exemple:



- Décalage: lire un jeton supplémentaire de l'entrée.
- Réduction: remplacer la partie droite d'une règle de production, qui correspond à une sous chaîne particulière, par la partie gauche de la règle.
- Si la sous chaîne est bien choisie, une dérivation par la droite inversée est effectuée.

### Exemple



#### Soit:

$$\rightarrow$$
 S  $\rightarrow$  aABe

$$A \rightarrow Abc \mid b$$

$$B \rightarrow d$$

#### Entrée:

$$(A \rightarrow b)$$

$$(A \rightarrow Abc)$$

$$(B \rightarrow d)$$

$$(S \rightarrow aABe)$$

**S** 

#### Dn voit bien la dérivation par la droite inversée

► S  $\rightarrow$  aABe  $\rightarrow$  aAde  $\rightarrow$  aAbcde  $\rightarrow$  abbcde

# ÉCOLE POLYTECHNIQUE M O N T R É A L

## Handle (manche)

#### Définition informelle

Sous-chaîne qui correspond à la partie droite d'une production et pour laquelle une réduction correspond à un pas vers une bonne dérivation par la droite inversée.

#### **Exemple:**

Arr S ightharpoonup aABe

 $A \rightarrow Abc \mid b$ 

 $B \rightarrow d$ 

#### Entrée:

▶ a**b**bcde

(handle: b)

▶ a**Abc**de

(handle: Abc)

▶ aA**d**e

(handle: d)

aABe

(handle: aABe)

**S** 



## Handle (manche)

#### Définition formelle:

- Un handle de  $\gamma$  est une production  $A \rightarrow \beta$  et une position dans  $\gamma$  tels que le remplacement de  $\beta$  par A produit  $\gamma^{-1}$ , où la dérivation droite de  $\gamma^{-1}$  donne  $\gamma$ .
- Si on a  $\stackrel{S}{\Rightarrow} \stackrel{\alpha Aw}{\Rightarrow} \stackrel{\alpha \beta w}{\Rightarrow}$ , alors la production  $A \to \beta$  dans la position qui suit  $\alpha$  est un handle de  $\alpha\beta\omega$

#### Notes:

- La chaîne  $\omega$  doit contenir seulement des symboles terminaux.
- Si la grammaire est ambiguë, il peut exister plus d'une dérivation à droite et donc plusieurs handles pour  $\gamma$ .
- Si la grammaire est non-ambiguë, chaque chaîne  $\gamma$  a un seul handle.

## Handle (manche) Ambiguïté



Considérez la grammaire suivante:

$$E \rightarrow E + E \mid E * E \mid (E) \mid id$$

E	$\stackrel{rm}{\Rightarrow} \underline{\mathbf{E} * \mathbf{E}}$	Е	$\stackrel{rm}{\Rightarrow} \mathbf{\underline{E}} + \mathbf{\underline{E}}$
E*E	$\stackrel{rm}{\Rightarrow} E * \underline{id}$	E + E	$\stackrel{rm}{\Rightarrow} E + \underline{E} * \underline{E}$
E*id	$\stackrel{rm}{\Rightarrow} \underline{\mathbf{E} + \mathbf{E}} * id$	E + E * E	$\stackrel{rm}{\Rightarrow} E + E * \underline{id}$
E + E * id	$\stackrel{rm}{\Rightarrow}$ E + <u>id</u> * id	E + E * id	$\stackrel{rm}{\Rightarrow}$ E + <u>id</u> * id
E + id * id	$\stackrel{rm}{\Rightarrow} \underline{id} + id * id$	E + id * id	$\stackrel{rm}{\Rightarrow} \underline{id} + id * id$

## Handle pruning (élagage du manche)



Soit la séquence de dérivations suivante:

$$S = \gamma_0 \Rightarrow \gamma_1 \Rightarrow \gamma_2 \Rightarrow \cdots \Rightarrow \gamma_{n-1} \Rightarrow \gamma_n = w$$

Le handle pruning permet de reconstruire la dérivation à droite inversée.

- Principe de base:
  - Identifier le handle  $β_n$  dans  $γ_n$
  - ► Réduire  $\beta_n$  par la tête de la production pertinente  $A_n \rightarrow \beta_n$  pour obtenir  $\gamma_{n-1}$ .
- La localisation d'un handle n'a pas été expliquée encore.

# ÉCOLE POLYTECHNIQUE M O N T R É A L

#### Exercice 2

- ▶ Soit la grammaire  $S \rightarrow 0 S I \mid 0 I$ 
  - Calculer le *handle* pour chacune des dérivations à droite inversées à partir de la chaîne 000 | 1 |
- ▶ Soit la grammaire  $S \rightarrow SS + |SS*|a$ 
  - Calculer le handle pour chacune des dérivations à droite inversées à partir de la chaîne aaa\*a++

# ÉCOLE POLYTECHNIQUE M O N T R É A L

## Exercice 2 (solution)

- $I. \quad S \rightarrow 0 S I \mid 0 I$ 
  - Entrée:
  - ▶ 00**0** | | | (handle: 01)
  - 00\$11 (handle: 0\$1)
  - **OSI** (handle: OSI)
  - **S**
- 2.  $S \rightarrow SS + |SS*|a$

#### Entrée:

- **a**aa\*a++ (handle: a)
- ► S**a**a\*a++ (handle: a)
- $SSa^*a++$  (handle: a)
- ► S**S**\*a++ (handle: SS\*)
- SSa++ (handle: a)
- ▶ S**SS+**+ (handle: SS+)
- ► SS+ (handle: SS+)
- S

## Parseur décalage/réduction (shift-reduce parsing)



#### Problématique

- Localiser un handle
- Choisir la production à appliquer

#### Structures utilisées

- Pile (stack)
- Tampon d'entrée (input buffer)

#### STACK §

INPUT w \$

### Symboles spéciaux

- Fond de la pile: \$
- Fin de l'entré:\$

## Parseur décalage/réduction Implémentation



- Algorithme:
  - RÉPÉTER
    - Décaler 0 ou plus de symboles d'entrée sur la pile jusqu'à la formation d'un handle B sur la pile
    - 2. Réduire B par la partie gauche de la règle appropriée
  - Tant que (pas d'erreur) ou (état d'acceptation)
- L'état d'acceptation est défini comme le moment où la pile contient le symbole de départ et le tampon d'entrée est vide.

STACK	INPUT
\$ S	\$

## Parseur décalage/réduction Actions possibles



- Il y a quatre actions pouvant être effectuées par le parseur:
  - Décalage (shift): le prochain symbole d'entrée est empilé sur la pile
  - Réduction (reduce): un handle se trouve sur le dessus de la pile
    - Identifier le handle à réduire sur le dessus de la pile
    - 2. Trouve la production
    - Remplacer la partie DROITE du handle, sur la pile
  - Note: le handle apparaît toujours sur le dessus de la pile, JAMAIS à l'intérieur (explication: entrée traitée de gauche à droite + dérivation à droite)

## Parseur décalage/réduction Actions possibles



- Acceptation: terminaison du parsage avec succès
- **Erreur:** détection d'une erreur syntaxique. Mise en marche de routine de correction d'erreurs.

STACK	INPUT	ACTION
\$	$\mathbf{id}_1*\mathbf{id}_2\$$	shift
$\mathbf{\$id}_1$	$*id_2$ \$	reduce by $F \rightarrow id$
F	$*id_2\$$	reduce by $T \rightarrow F$
T	$*id_2$ \$	shift
T *	$\mathbf{id}_2\$$	shift
$T * id_2$	\$	reduce by $F \to id$
T * F	\$	reduce by $T \to T * F$
T	\$	reduce by $E \to T$
\$E	\$	accept

Figure 4.28: Configurations of a shift-reduce parser on input id<sub>1</sub>\*id<sub>2</sub>

## Parseur décalage/réduction Conflits durant le parsage



- Pour certaines grammaires CFG, tous les parseurs par décalage/réduction atteignent une configuration où l'état de la pile et le prochain symbole d'entrée ne permettent pas de décider entre:
  - Décaler ou réduire (shift/reduce conflict)
  - 2. Réduire ou réduire (reduce/reduce conflict), à cause de plusieurs productions possibles.
- $\triangleright$  Ces grammaires ne sont pas LR(k).
  - Les langages de programmation ont habituellement des grammaires LR(1).
  - Une grammaire ambiguë n'est pas LR(k), pour tout k.
  - On lève l'ambiguïté shift/reduce en priorisant la réduction ou le décalage.



## Conflits (exemple)

Soit la grammaire:

```
stmt \rightarrow if \ expr \ then \ stmt
| if expr \ then \ stmt \ else \ stmt
| other
```

▶ Et la configuration:

```
STACK INPUT \cdots if expr then stmt else \cdots $
```

- On a un conflit décalage/réduction
  - Dans ce cas, on voudrait probablement faire un décalage afin d'associer chaque else au then précédent le plus près.



## Conflits (exemple 2)

 Soit une grammaire qui utilise les parenthèses pour les appels de procédures et pour la référence à des cases dans un tableau:

```
(1)
                  stmt \rightarrow id (parameter\_list)
(2)
                  stmt \rightarrow expr := expr
      parameter\_list \rightarrow parameter\_list, parameter
      parameter\_list \rightarrow parameter
(5)
           parameter \rightarrow id
(6)
                         → id ( expr_list )
(7)
                          \rightarrow id
                  expr
(8)
             expr\_list \rightarrow expr\_list, expr
(9)
             expr\_list
```

Figure 4.30: Productions involving procedure calls and array references



## Conflits (exemple 2)

Soit la configuration suivante, pour une instruction p(i, j):

- id doit être réduit, mais il y a deux productions possibles (5 et
  7)
  - (5) est correcte si p est une procédure
  - (7) est correcte si p est un tableau
- On a un conflit réduction/réduction
  - Solution possible:
     Changer le jeton id de la production (I) par un jeton procid, et modifier l'analyseur lexical pour différentier les types de jetons.

# ÉCOLE POLYTECHNIQUE M O N T R É A L

#### Exercice 3

- ▶ Soit la grammaire  $S \rightarrow 0 S I \mid 0 I$ 
  - Donner l'état de la pile et du tampon d'entrée pour chaque étape du parsage ascendant de la chaîne 000 l l l
- ▶ Soit la grammaire  $S \rightarrow SS + |SS*|a$ 
  - 2. Donner l'état de la pile et du tampon d'entrée pour chaque étape du parsage ascendant de la chaîne aaa\*a++



#### Parseur LR

- Capables de reconnaître presque tous les langages libres de contexte
  - Il existe des grammaires CFG qui ne sont pas LR, mais elles peuvent être évitées dans le contexte des langages de programmation.
- On utilise habituellement les parseurs à décalage/réduction sans retour-arrière (backtracking)
- $\blacktriangleright \mathsf{LR}(\mathsf{I}) \supset \mathsf{LL}(\mathsf{I})$
- Les erreurs syntaxiques sont détectées aussitôt que possible dans lecture de gauche à droite de l'entrée



#### Parseur LR

- La construction « à la main » est très exigeante; on utilise des générateurs de parseurs LR
  - Yacc, Bison, SableCC, etc.
- ▶ Types de tables d'analyse LR:
  - ▶ Simple LR (SLR): table de petite taille, moins puissante
  - ▶ Canonical LR (LR): table de grande taille, plus puissante
  - ► Look Ahead LR (LALR): table de taille moyenne et puissance intermédiaire
- L'algorithme de parsage est toujours le même, peu importe le type de table utilisé



## Items LR(0)

- Les items permettent de déterminer quand faire un shift ou un reduce
- Un item LR(0) (ou simplement item) d'une grammaire G est une production de G avec un point dans une position quelconque de la production.
  - Pour la production  $A \rightarrow XYZ$  items suivants:  $A \rightarrow XYZ$   $A \rightarrow XYZ$  $A \rightarrow XYZ$
  - Pour la production  $A \rightarrow \epsilon$ , on a un seul item:  $A \rightarrow ...$
- Un item indique jusqu'où une production a été traitée jusqu'à maintenant.
  - Exemple:  $A \rightarrow X \cdot YZ$  signifie qu'une chaîne dérivable à partir de X a été traitée et que nous espérons maintenant voir une chaîne dérivable à partir de YZ.

# ÉCOLE POLYTECHNIQUE M O N T R É A L

## Automate LR(0)

- Automate déterministe fini permettant d'effectuer les décisions de parsage.
- ▶ Est construit grâce à l'ensemble LR(0) canonique
  - Il s'agit d'un ensemble d'ensembles (collection of sets) d'items
- Trois éléments doivent être définis pour construire l'ensemble LR(0) canonique:
  - Grammaire augmentée
  - Fonction CLOSURE
  - Fonction GOTO



## Grammaire augmentée

Supposons une grammaire G avec un symbole de départ S.

- La grammaire augmentée G' est G avec un nouveau symbole de départ S'et la production S'→ S.
- But du nouveau symbole de départ: permettre au parseur de savoir quand il doit arrêter de parser et accepter l'entrée.



#### Fonction CLOSURE

- Supposons que l'est un ensemble d'items d'une grammaire G.
- CLOSURE(I) est l'ensemble d'items construit à partir de I via les deux règles suivantes:
  - Initialement, ajouter chaque item de I dans CLOSURE(I)
  - 2. Si A  $\rightarrow \alpha \cdot B\beta$  est dans CLOSURE(I) et que B  $\rightarrow \gamma$  est une production, alors ajouter l'item B  $\rightarrow \gamma$  à CLOSURE(I), s'il n'est pas déjà présent.
    - Appliquer cette règle jusqu'à ce qu'aucun nouvel item ne puisse être ajouté à CLOSURE(I)

## Fonction CLOSURE Exemple



Soit la grammaire suivante:

- ▶ Si  $I = \{ [E' \rightarrow \cdot E] \}$ , alors CLOSURE(I) contient les éléments suivants:
  - $E' \rightarrow E$
  - $E \rightarrow E + T$   $E \rightarrow T$
  - $T \rightarrow T * F$   $T \rightarrow F$
  - $E \rightarrow \cdot (E)$   $E \rightarrow \cdot id$

## Fonction CLOSURE Algorithme



```
 \begin{array}{c} {\rm SetOfItems\ CLOSURE}(I)\ \{\\ J=I;\\ {\bf repeat}\\ {\bf for\ (\ each\ item\ }A\to\alpha\cdot B\beta\ {\rm in\ }J\ )\\ {\bf for\ (\ each\ production\ }B\to\gamma\ {\rm of\ }G\ )\\ {\bf if\ (\ }B\to\cdot\gamma\ {\rm is\ not\ in\ }J\ )\\ {\rm add\ }B\to\cdot\gamma\ {\rm to\ }J;\\ {\bf until\ no\ more\ items\ are\ added\ to\ }J\ {\rm on\ one\ round};\\ {\bf return\ }J;\\ \} \end{array}
```

Figure 4.32: Computation of CLOSURE



#### Fonction GOTO

- ▶ GOTO(*I*, *X*)
  - ▶ *l* est un ensemble d'items
  - X est un symbole de la grammaire
- ▶ GOTO(I, X) est défini comme la fermeture (CLOSURE) de l'ensemble de tous les items [ $A \rightarrow \alpha X \cdot \beta$ ] tel que [ $A \rightarrow \alpha \cdot X\beta$ ] est dans I.
  - Intuitivement, la fonction GOTO est utilisée pour définir les transitions dans l'automate LR(0).
  - Les états correspondent aux ensembles d'items, alors que GOTO(I, X) spécifie la transition de l'état I sous l'entrée X.

## Fonction GOTO Exemple



▶ Si  $I = \{ [E' \rightarrow E \cdot], [E \rightarrow E \cdot + T] \}$  alors GOTO(I, +) contient les éléments suivants:

$$E \rightarrow E + \cdot T$$

$$T \rightarrow \cdot T * F$$

$$T \rightarrow \cdot F$$

$$F \rightarrow \cdot (E)$$

$$F \rightarrow \cdot \mathbf{id}$$

On a fait progresser le point « par-dessus » le symbole +, puis on calcule la fermeture (CLOSURE) sur la règle E → E+·T

## Fonction GOTO Algorithme



L'algorithme suivant construit C, l'ensemble d'ensembles d'items LR(0) pour une grammaire augmentée G'

```
void items(G') {
C = \text{CLOSURE}(\{[S' \to \cdot S]\});
repeat

for ( each set of items I in C )

for ( each grammar symbol X )

if ( \text{GOTO}(I, X) is not empty and not in C )

add \text{GOTO}(I, X) to C;

until no new sets of items are added to C on a round;
}
```

## Détermination des ensembles d'items LR(0)



Construisons les ensembles d'items de la grammaire augmentée suivante, en calculant aussi les GOTO:

$$\begin{array}{ccccc} E' & \rightarrow & E \\ E & \rightarrow & E+T \mid T \\ T & \rightarrow & T*F \mid F \\ F & \rightarrow & (E) \mid \mathbf{id} \end{array}$$

# ÉCOLE POLYTECHNIQUE M O N T R É A L

#### Utilité des GOTO et CLOSURE




Figure 4.31: LR(0) automaton for the expression grammar (4.1)

# ÉCOLE POLYTECHNIQUE M O N T R É A L

#### Exercice 4

- ▶ Soit la grammaire  $S \rightarrow SS + |SS*|a$
- I. Augmenter la grammaire
- Calculer les ensembles d'items pour la grammaire ainsi que la fonction GOTO pour chacun des ensembles obtenus.

**Indice**: commencez par  $I_0$  = CLOSURE( $r \ge gle$  de  $d \le part$ )