







LOG3210 Éléments de langage et compilateurs

Traduction dirigée par la syntaxe

PLAN

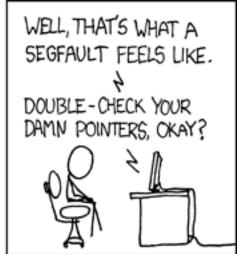
1. Chapitre 5 – Traduction dirigée par la syntaxe

Compiler Complaint

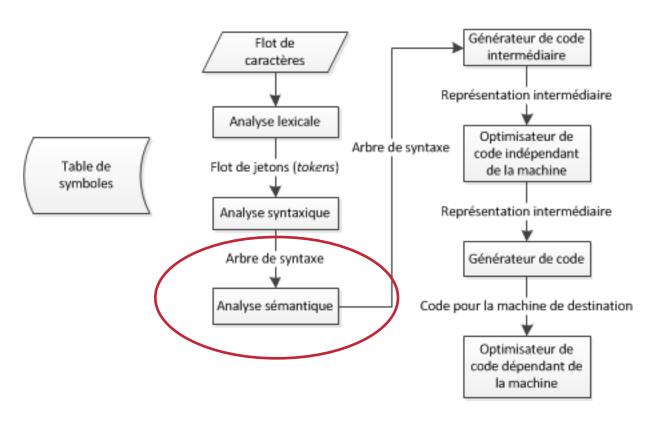








PHASES D'UN COMPILATEUR





Analyse sémantique : Vérification ou transformation sur l'arbre de syntaxe.



LOG3210 Cours 5

Traduction dirigée par la syntaxe

Arbres de syntaxe abstraits (AST)



- Très importants pour les environnements intégrés de développement (IDE)
- Permettent de séparer la traduction de l'analyse syntaxique
- Représentation:
 - Forme condensée d'un arbre de parsage
 - Les opérateurs et les mots clefs sont plutôt associés au nœud racine
 - Les séquences de production avec seulement un symbole non terminal à droite peuvent être compressés

ÉCOLE POLYTECHNIQUE M O N T R É A L

AST vs arbres de parsage

- Un AST ne représente pas nécessairement chaque détail du langage
 - Par exemple, les parenthèses sont implicites
 - Un if-else pourrait être représenté différemment
- L'AST est, à toutes fins pratiques, insensible à la grammaire, ce qui n'est pas le cas de l'arbre de parsage.
- Dans un AST, les nœuds internes sont des structures du langage de programmation.
- Dans un arbre de parsage, les nœuds internes sont des non terminaux
 - Certains non terminaux sont des helpers qui ne seront pas dans un AST

Arbres syntaxiques abstraits Avantages



- Une grammaire qui est adéquate pour l'analyse syntaxique pourrait ne pas refléter la structure hiérarchique d'un langage de programmation
- Les méthodes d'analyses syntaxique imposent un ordre dans la construction de l'arbre de parsage. Cet ordre pourrait ne pas être l'ordre dans lequel les informations deviennent disponibles dans les structures du langage

Exemple



Exemple avec la grammaire

- \rightarrow expr \rightarrow expr + term | expr term | term
- ▶ Term \rightarrow 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9



- SDD (Définitions Dirigées par la Syntaxe)
 - Spécifications de haut niveau pour la traduction
 - Spécifie la valeur d'attributs en associant des règles sémantiques aux productions de la grammaire.
- Exemple:

PRODUCTION SEMANTIC RULE
$$E \to E_1 + T \qquad E.code = E_1.code \parallel T.code \parallel '+' \qquad (5.1)$$

SDD



Définition

- Grammaire libre de contexte avec un ensemble d'attributs et de règles
- Les attributs sont associés à des symboles de la grammaires
 - Par exemple, X.a, où a est un attribut du symbole X
- Les règles sont associées à des productions

ÉCOLE POLYTECHNIQUE M O N T R É A L

SDD vs SDT

- Un schéma de traduction dirigée par la syntaxe (SDT) spécifie l'ordre de l'évaluation des règles sémantiques.
- Une SDD peut être implémentée par une SDT.
- Exemple:

$$E \rightarrow E_1 + T \quad \{ \text{ print '+' } \}$$
 (5.2)

ÉCOLE POLYTECHNIQUE M O N T R É A L

SDD / SDT - Applications

Exemples d'applications:

- Génération d'AST
- Inférence de types
- Génération de code
- Construction de graphe de flux de contrôle
- Analyse de programme:
 - Détection de clones logiciels
 - Analyses de sécurité (SQLi, XSS, etc.)
- ▶ IDE (Eclipse, NetBeans, etc.)
- Traduction de programmes
- Etc.



SDD - Attributs

Deux types d'attributs

Synthétisés

- Pour un non terminal A, représenté par un nœud N, l'attribut est défini par une règle sémantique associée à une production qui a N en tête.
- Attribut défini en fonction des valeurs des attributs des enfants de N et de N lui-même.

Hérités

- Pour un non terminal B, représenté par un nœud N, l'attribut est défini par une règle sémantique associée à une production qui a le parent de N en tête et où N appartient à la partie droite de la règle.
- Attribut défini en fonction des valeurs des attributs du parent de N, de N lui-même et des frères de N.



SDD - Attributs

- Les symboles terminaux possèdent seulement des attributs synthétisés par l'analyseur lexical.
- Le symbole START ne possède pas d'attribut hérité.
- Il est toujours possible de réécrire une SDD afin d'utiliser seulement des attributs synthétisés (mais il est souvent plus naturel d'utiliser des attributs hérités)



Attributs synthétisés

- SDD S-attributed
 - Il s'agit d'une SDD qui n'implique que des attributs synthétisés
- Une SDD S-attributed s'implémente naturellement avec un parseur LR
- Un arbre de parsage peut TOUJOURS être annoté par une évaluation bottom-up des règles sémantiques d'une SDD qui est S-attributed



SDD - Exemple

- Utilisons une SDD S-attributed pour évaluer la valeur des expressions arithmétiques:
- On considère ici que le terminal **n** signale la fin d'une expression.

	PRODUCTION	SEMANTIC RULES
1)	$L \to E \mathbf{n}$	
2)	$E \rightarrow E_1 + T$	
3)	$E \to T$	
4)	$T \rightarrow T_1 * F$	
5)	$T \to F$	
6)	$F \rightarrow (E)$	
7)	$F o \mathbf{digit}$	



SDD - Exemple

Solution:

	PRODUCTION	Semantic Rules
1)	$L \to E \mathbf{n}$	L.val = E.val
2)	$E \rightarrow E_1 + T$	$E.val = E_1.val + T.val$
3)	$E \to T$	E.val = T.val
4)	$T \rightarrow T_1 * F$	$T.val = T_1.val \times F.val$
5)	$T \to F$	T.val = F.val
6)	$F \rightarrow (E)$	F.val = E.val
7)	$F o \mathbf{digit}$	$F.val = \mathbf{digit}.lexval$



SDD – Exemple 2

 Utilisons la SDD pour transformer une expression infixe en expression post-fixe

PRODUCTION	SEMANTIC RULES
$expr \rightarrow expr_1 + term$	
$expr \rightarrow expr_1$ - $term$	
$expr \rightarrow term$	
$term \rightarrow 0$	
$term o exttt{1}$	
$term \rightarrow 9$	



SDD – Exemple 2

Solution

PRODUCTION	SEMANTIC RULES
$expr \rightarrow expr_1 + term$	$expr.t = expr_1.t \mid\mid term.t \mid\mid '+'$
$expr \rightarrow expr_1$ - $term$	$expr.t = expr_1.t \mid term.t '-'$
expr o term	expr.t = term.t
term ightarrow 0	term.t = '0'
$term ightarrow exttt{1}$	term.t = '1'
$term \rightarrow 9$	term.t = '9'



SDD – Exemple 3

- Exemple d'utilisation d'attributs hérités et synthétisés
 - On propage les résultats partiels vers la droite (noeuds frères) et vers le bas (noeuds enfants), ce sont des attributs hérités.
 - On propage les résultats finaux vers le haut (noeud parent), ce sont des attributs synthétisés

-	PRODUCTION	SEMANTIC RULES
1)	$T \to F T'$	T'.inh = F.val T.val = T'.syn
2)	$T' \to \ast F T_1'$	$T_1'.inh = T'.inh \times F.val$ $T'.syn = T_1'.syn$
3)	$T' \to \epsilon$	T'.syn = T'.inh
4)	$F \to \mathbf{digit}$	$F.val = \mathbf{digit}.lexval$



Exercice 1

Ecrire une SDT qui calcule le nombre d'instructions (représentées par le non terminal S) dans un programme et qui affiche ce nombre une seule fois (via la fonction print qui prend un paramètre).

- $P' \rightarrow P$
- $P \rightarrow SP_1$
- $P \rightarrow S$
- $\triangleright S \rightarrow \{A\}$
- $\rightarrow A \rightarrow p s$



Exercice 1 (solution)

Règ	les de	pro	duction	Actions sémantiques
(0)	P'	\rightarrow	P	print(P.s)
(1)	P	\rightarrow	SP_1	$P.s = 1 + P_1.s$
(2)	P	\rightarrow	S	P.s = 1
(3)	S	\rightarrow	$\{A\}$	
(4)	A	\rightarrow	p s	



Arbre de parsage annoté

Un arbre de parsage annoté montre les valeurs des attributs de chacun des nœuds.

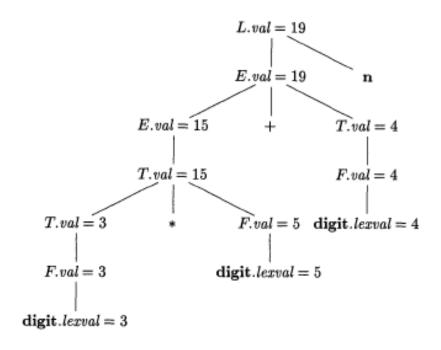


Figure 5.3: Annotated parse tree for 3 * 5 + 4 n



Arbre de parsage annoté

- Construisons l'arbre de parsage annoté pour l'expression suivante:
 - 1*2*3*(4+5) n

	PRODUCTION	SEMANTIC RULES
1)	$L \to E \mathbf{n}$	L.val = E.val
2)	$E \rightarrow E_1 + T$	$E.val = E_1.val + T.val$
3)	$E \to T$	E.val = T.val
4)	$T \rightarrow T_1 * F$	$T.val = T_1.val \times F.val$
5)	$T \to F$	T.val = F.val
6)	$F \rightarrow (E)$	F.val = E.val
7)	$F o \mathbf{digit}$	$F.val = \mathbf{digit}.\mathbf{lexval}$



Graphe de dépendances

- Un graphe de dépendances indique le flux d'informations entre les différents attributs.
 - Un arc d'un attribut à un autre signifie que la valeur du premier attribut est nécessaire pour calculer le deuxième.
- Le graphe de dépendances possède un nœud pour chaque attribut de chacun des nœuds dans l'arbre de parsage.



Graphe des dépendances

Exemple:

- Les traits pointillés représentent les arcs de l'arbre de parsage.
- Les traits pleins représentent les arrêtes du graphe de dépendances.

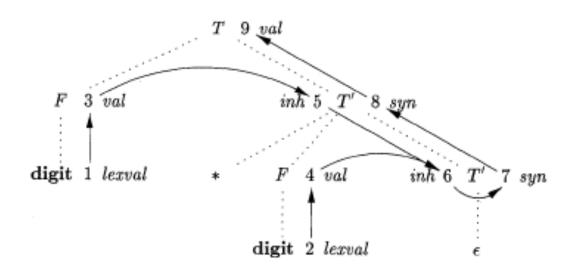


Figure 5.7: Dependency graph for the annotated parse tree of Fig. 5.5

Construction du graphe de dépendance



- Créer un nœud pour chaque attribut de chaque nœud de l'arbre de parsage.
- Si un attribut synthétisé A.b est défini en fonction de l'attribut X.c, ajouter un arc du nœud représentant X.c vers le nœud représentant A.b.
- Si un attribut hérité B.c est défini en fonction de l'attribut X.a, ajouter un arc du nœud représentant X.a vers le nœud représentant B.c.



Ordre topologique

- Un ordre topologique d'un graphe dirigé sans cycle est un ordre sur les nœuds du graphe tel que les nœuds de départ des arcs précèdent les nœuds d'arrivée.
- Tous les ordres topologiques d'un graphe de dépendances représentent un ordre valide d'évaluation des règles sémantiques.
- Exercice: identifier deux ordre topologiques distincts dans le graphe de la diapositive précédente



Classes de SDD

Certaines classes de SDD sont définies afin de garantir l'existence d'une ordre topologique dans le graphe des dépendances (en empêchant la présence d'un cycle).

S-Attributed

- Tous les attributs sont synthétisés.
- Attributs évalués en ordre bottom-up.
- Traversement de l'arbre de parsage en postordre.

Implantation par parseur LR

Les règles de traduction sont éxécutées quand le parseur fait un reduce.



Classes de SDD

L-attributed

- Concept de base: les arcs du graphe des dépendances peuvent aller de gauche à droite, mais pas de droite à gauche
- Les attributs peuvent toujours être évalués en traversant l'arbre de parsage en pré-ordre

Propriété

Les SDD basées sur une grammaire LL(I) appartiennent aux définitions *L-attributed*



Définitions L-attributed

- Plus formellement, chaque attribut doit être soit:
 - Synthétisé
 - Hérité, avec les limitations suivantes. Soit une production $A \rightarrow X_1 X_2 ... X_n$ et un attribut hérité X_i . La règle sémantique ne peut utiliser que
 - Des attributs hérités associés à A
 - Des attributs hérités ou synthétisés associés aux symboles $X_1X_2...X_{i-1}$ situés à gauche de X_i
 - Des attributs hérités ou synthétisés associés à X_i , mais seulement de façon à ce qu'il n'y ait pas de cycles dans le graphe des dépendances formé par les attributs de X_i



Implantation SDD L-attributed

- Généralement implantées dans un parseur LL.
- Les actions qui calculent des attributs hérités pour un non terminal A sont exécutées immédiatement avant le traitement de A. S'il existe des dépendances entre plusieurs attributs, les ordonner correctement.
- Les actions qui calculent des attributs synthétisés de la tête de la production sont exécutées après avoir traité tous les nœuds de la production.



Classes de SDD - Exemples

Les SDD suivantes sont-elles L-attributed?

PRODUCTION SEMANTIC RULE
$$T \to F T'$$
 $T'.inh = F.val$ $T' \to *F T'_1$ $T'_1.inh = T'.inh \times F.val$

PRODUCTION SEMANTIC RULES
$$A \rightarrow B \ C$$
 $A.s = B.b;$ $B.i = f(C.c, A.s)$



SDD – Effets de bord

- Effets de bord
 - Impression
 - Références globales
- Calcul des valeurs des attributs sur les nœuds de l'arbre de parsage
 - Annotation ou décoration de l'arbre de parsage

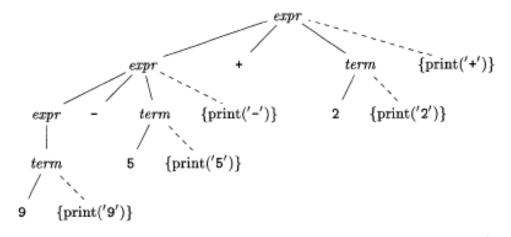


Figure 2.14: Actions translating 9-5+2 into 95-2+



Exercice 2

- En utilisant un effet de bord par appel de fonction, écrire une SDD pour ajouter chaque variable du système dans la table de symboles.
 - Supposez l'existence d'une fonction addType(varName, varType) qui ajoute la variable varName, de type varType, dans la table de symboles
- Dessiner le graphe des dépendances pour la déclaration suivante: float id₁, id₂, id₃

	PRODUCTION	Semantic Rules
1)	$D \rightarrow T L$	
2)	$T \rightarrow \mathbf{int}$	
3)	$T \rightarrow \mathbf{float}$	
4)	$L \rightarrow L_1$, id	
5)	$L \to \mathbf{id}$	



Exercice 2 - Solution

	PRODUCTION	SEMANTIC RULES
1)	$D \to T L$	L.inh = T.type
2)	$T o \mathbf{int}$	T.type = integer
3)	$T \to \mathbf{float}$	T.type = float
4)	$L \to L_1$, id	$L_1.inh = L.inh$
		addType(id.entry, L.inh)
5)	$L \to \mathbf{id}$	addType(id.entry, L.inh)

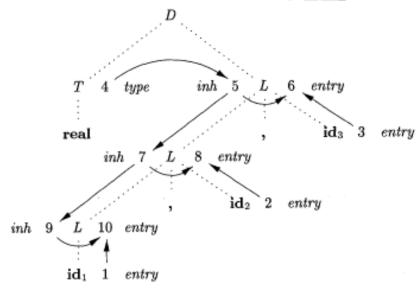


Figure 5.9: Dependency graph for a declaration float id1, id2, id3

Applications de la SDD Exemple



- ▶ Il est possible de construire un AST en utilisant la SDD
- Une technique similaire peut être utilisée pour générer le code intermédiaire et faire de la vérification de types

	PRODUCTION	SEMANTIC RULES
1)	$E \rightarrow E_1 + T$	$E.node = new Node('+', E_1.node, T.node)$
2)	$E \rightarrow E_1 - T$	$E.node = new Node('-', E_1.node, T.node)$
3)	$E \to T$	E.node = T.node
4)	$T \rightarrow (E)$	T.node = E.node
5)	$T o \mathbf{id}$	T.node = new Leaf(id, id.entry)
6)	$T\to \mathbf{num}$	T.node = new Leaf(num, num.val)

Figure 5.10: Constructing syntax trees for simple expressions

Applications de la SDD Exemple



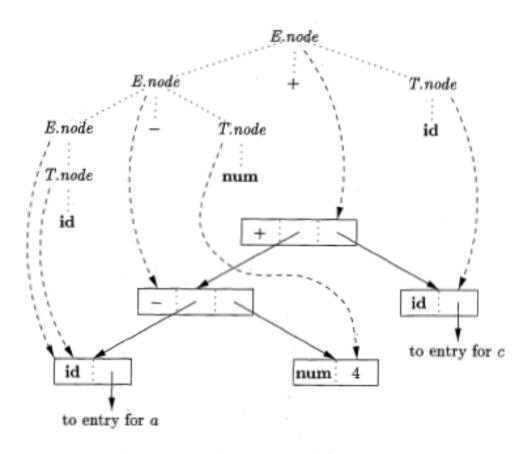


Figure 5.11: Syntax tree for a - 4 + c

ÉCOLE POLYTECHNIQUE M O N T R É A L

Schémas de traduction

Le but est de convertir les SDD en SDT afin d'exécuter les actions définies par la SDD au bon moment.

- Cas le plus simple:
 - ▶ SDD S-attributed avec un parseur bottom-up
 - On peut alors simplement effectuer les actions en même temps que les réductions du parseur LR
 - On maintiendra une pile d'attributs synthétisés en plus de la pile d'états habituelle.
- Exemple sur la grammaire des expressions du cours précédent.



Schéma de traduction

- Si la SDD est L-attributed, une implantation par parseur LL est généralement plus appropriée.
- Une fonction par non-terminal.
- La fonction reçoit les attributs hérités en paramètre et retourne les attributs synthétisés.
- Exemple sur la grammaire JSON de l'intra H13.



Perspective générale

- Les activités de rétro-ingénierie peuvent être considérées comme des problèmes de Traduction Dirigée par la Syntaxe (SDT) où
 - Le langage de départ représente un certain niveau d'abstraction
 - Le langage cible est à un niveau d'abstraction supérieur
- La représentation d'un niveau d'abstraction revient à la conception de langages
- Les problèmes de rétro-ingénierie reviennent à trouver une SDT adéquate

ÉCOLE POLYTECHNIQUE M O N T R É A L

Outils de traduction

- Outils pour implanter des SDD
 - YACC
 - Méthodes négligentes, approche ascendante
 - TXL
 - Méthodes récursives, strictement fonctionnel
 - Méthodes hybrides
 - Sauvegardent le AST comme une structure de données et utilisent un paradigme pour effectuer les transformations désirées
 - JavaCC
 - Méthodes récursives (actions dans les règles de production)
 - Utilisation de visiteurs (action sur l'arbre a posteriori)



Exercice supplémentaire

Soit la grammaire suivante.

$$E \rightarrow E + T \mid T$$

 $T \rightarrow \text{num} \cdot \text{num} \mid \text{num}$

- 1. Donnez un SDD permettant de déterminer le type de chaque terme T et expression E
- 2. Étendez votre SDD pour traduire les expressions dans des expressions en notation postfixe.